

Attention Is All You Need

从循环序列模型到纯注意力的 Transformer

Ashish Vaswani, Noam Shazeer, Llion Jones, Aidan N. Gomez, Niki Parmar, Jakob Uszkoreit, Łukasz Kaiser, Illia Polosukhin · NeurIPS 2017 · 2017

目录

01 · 问题：序列建模为何难以并行	3
02 · 设计：把编码器—解码器改造成注意力网络	4
03 · 主要证据：机器翻译质量与训练代价	6
04 · 消融：性能来自怎样的配置组合	7
05 · 跨任务检验：成分句法解析	8
06 · 可视化与边界：学到了什么，尚未证明什么	9
07 · 证据来源与页面锚点	13

问题：序列建模为何难以并行

论文从循环模型的顺序瓶颈出发。

循环编码器-解码器按符号位置推进隐藏状态，因此训练样本内部的计算难以并行；长距离依赖还要经过更长的路径。卷积模型改善并行性，却仍需要随距离增长的路径。Transformer 的问题不是简单地增加一个注意力模块，而是询问：注意力能否承担整个转导过程。

TABLE 1: 不同层类型的复杂度、顺序操作与最大路径长度。 [T01]

Table 1: Maximum path lengths, per-layer complexity and minimum number of sequential operations for different layer types. n is the sequence length, d is the representation dimension, k is the kernel size of convolutions and r the size of the neighborhood in restricted self-attention.

Layer Type	Complexity per Layer	Sequential Operations	Maximum Path Length
Self-Attention	$O(n^2 \cdot d)$	$O(1)$	$O(1)$
Recurrent	$O(n \cdot d^2)$	$O(n)$	$O(n)$
Convolutional	$O(k \cdot n \cdot d^2)$	$O(1)$	$O(\log_k(n))$
Self-Attention (restricted)	$O(r \cdot n \cdot d)$	$O(1)$	$O(n/r)$

表格把核心权衡写清楚：无限制自注意力具有 $O(1)$ 顺序操作和 $O(1)$ 路径长度，但每层计算为 $O(n^2 \cdot d)$ ；循环层为 $O(n \cdot d^2)$ 且需要 $O(n)$ 顺序操作。

设计：把编码器—解码器改造成注意力网络

Transformer 的关键不是单个公式，而是各个子层如何组合。




Figure 1: The Transformer - model architecture.

Figure 1: Transformer 模型架构。 [F01]

左侧编码器堆叠多头自注意力与逐位置前馈层；右侧解码器增加对编码器输出的注意力，并以掩码阻止当前位置读取未来目标词。输入/输出嵌入与位置编码相加，残差连接和 LayerNorm 包围子层。




Figure 2: 缩放点积注意力与多头注意力。 [F02]

缩放点积注意力计算 $\text{softmax}(QK^T/\sqrt{d_k})V$ ；多头注意力先把 Q、K、V 投影到多个低维子空间，再并行计算并拼接。缩放用于抑制大点积把 softmax 推入小梯度区域。

基础模型使用 $d_{\text{model}}=512$ 、6 层、8 个头，每个头 $d_k=d_v=64$ ；前馈层内维度为 2048。解码器的未来位置掩码和移位输出保持自回归条件，而位置编码补回没有循环结构后丢失的顺序信息。

主要证据：机器翻译质量与训练代价

翻译实验是论文最重要的实证检验。

在 WMT 2014 English-to-German 上，Transformer big 达到 28.4 BLEU，base 达到 27.3；在 English-to-French 上，big 达到 41.8 BLEU。论文还报告 big 模型在 8 张 P100 GPU 上训练 3.5 天，并用估算 FLOP 与此前系统比较。

TABLE 2: WMT 2014 翻译 BLEU 与训练 FLOP 比较。 [T02]

Table 2: The Transformer achieves better BLEU scores than previous state-of-the-art models on the English-to-German and English-to-French newstest2014 tests at a fraction of the training cost.

Model	BLEU		Training Cost (FLOPs)	
	EN-DE	EN-FR	EN-DE	EN-FR
ByteNet [18]	23.75			
Deep-Att + PosUnk [39]		39.2		$1.0 \cdot 10^{20}$
GNMT + RL [38]	24.6	39.92	$2.3 \cdot 10^{19}$	$1.4 \cdot 10^{20}$
ConvS2S [9]	25.16	40.46	$9.6 \cdot 10^{18}$	$1.5 \cdot 10^{20}$
MoE [32]	26.03	40.56	$2.0 \cdot 10^{19}$	$1.2 \cdot 10^{20}$
Deep-Att + PosUnk Ensemble [39]		40.4		$8.0 \cdot 10^{20}$
GNMT + RL Ensemble [38]	26.30	41.16	$1.8 \cdot 10^{20}$	$1.1 \cdot 10^{21}$
ConvS2S Ensemble [9]	26.36	41.29	$7.7 \cdot 10^{19}$	$1.2 \cdot 10^{21}$
Transformer (base model)	27.3	38.1	$3.3 \cdot 10^{18}$	
Transformer (big)	28.4	41.8	$2.3 \cdot 10^{19}$	

Transformer big 的 En-De 28.4 和 En-Fr 41.8 是表中关键结果；base 也以较低估算代价取得较强 En-De 结果。

不能。Table 1 的 $O(1)$ 是顺序操作和路径长度的渐近性质，注意力仍有随 n^2 增长的层计算和内存压力。论文证明的是其报告设置下的质量与并行化组合，而不是硬件无关的速度定理。

消融：性能来自怎样的配置组合

Table 3 让‘注意力取代循环’这一口号变得更具体。

TABLE 3: TRANSFORMER 架构变化。 [T03]

Table 3: Variations on the Transformer architecture. Unlisted values are identical to those of the base model. All metrics are on the English-to-German translation development set, newstest2013. Listed perplexities are per-wordpiece, according to our byte-pair encoding, and should not be compared to per-word perplexities.

	N	d_{model}	d_{ff}	h	d_k	d_v	P_{drop}	ϵ_{ls}	train steps	PPL (dev)	BLEU (dev)	params $\times 10^6$	
base	6	512	2048	8	64	64	0.1	0.1	100K	4.92	25.8	65	
(A)					1	512	512				5.29	24.9	
					4	128	128				5.00	25.5	
					16	32	32				4.91	25.8	
					32	16	16				5.01	25.4	
(B)					16					5.16	25.1	58	
					32					5.01	25.4	60	
(C)	2									6.11	23.7	36	
	4									5.19	25.3	50	
	8									4.88	25.5	80	
		256				32	32				5.75	24.5	28
		1024				128	128				4.66	26.0	168
			1024								5.12	25.4	53
			4096								4.75	26.2	90
(D)							0.0				5.77	24.6	
							0.2				4.95	25.5	
									0.0	4.67	25.3		
									0.2	5.47	25.7		
(E)	positional embedding instead of sinusoids									4.92	25.7		
big	6	1024	4096	16				0.3	300K	4.33	26.4	213	

头数过少或过多、键维度变小、模型规模、dropout 和位置表示都会改变开发集结果；big 模型和大前馈层通常更强。正弦与学习位置嵌入在报告行中几乎相同，选择正弦编码带有外推假设。

因此，结果不应被解释为‘只要使用注意力就会提升性能’。头数、表示维度、规模、正则化和训练程序共同构成有效配置。

跨任务检验：成分句法解析

论文进一步问 Transformer 是否只适合机器翻译。

TABLE 4: 英语成分句法解析的 WSJ 23 F1。 [T04]

Table 4: The Transformer generalizes well to English constituency parsing (Results are on Section 23 of WSJ)

Parser	Training	WSJ 23 F1
Vinyals & Kaiser et al. (2014) [37]	WSJ only, discriminative	88.3
Petrov et al. (2006) [29]	WSJ only, discriminative	90.4
Zhu et al. (2013) [40]	WSJ only, discriminative	90.4
Dyer et al. (2016) [8]	WSJ only, discriminative	91.7
Transformer (4 layers)	WSJ only, discriminative	91.3
Zhu et al. (2013) [40]	semi-supervised	91.3
Huang & Harper (2009) [14]	semi-supervised	91.3
McClosky et al. (2006) [26]	semi-supervised	92.1
Vinyals & Kaiser et al. (2014) [37]	semi-supervised	92.1
Transformer (4 layers)	semi-supervised	92.7
Luong et al. (2015) [23]	multi-task	93.0
Dyer et al. (2016) [8]	generative	93.3

4 层 Transformer 在 WSJ-only discriminative 设置达到 91.3 F1，在 semi-supervised 设置达到 92.7 F1，超过表中多项此前系统；但表中 generative 的 93.3 仍更高，因此结论是强迁移表现而非全面胜出。

这个结果扩大了论文的范围，但不能替代更广泛的跨领域验证。它显示注意力架构能够处理结构约束很强、输出通常比输入更长的解析任务，同时也保留了比较表中未胜出的结果。

可视化与边界：学到了什么，尚未证明什么

附录图把注意力头的行为展示出来，但其证据等级不同于翻译表格。




Figure 3: 长距离依赖示例。 [F03]

不同颜色的线连接词语位置，展示若干头对长距离依赖的关注。




Figure 4: Two attention heads, also in layer 5 of 6, apparently involved in anaphora resolution. Top: Full attentions for head 5. Bottom: Isolated attentions from just the word 'its' for attention heads 5

Figure 4: 与指代消解相关的注意力头示例。 [F04]

图中展示 layer 5 的两个头在特定词语上的全注意力与孤立注意力。原文使用 apparently，说明这是解释性假设而非确定性证明。




Figure 5: 与句子结构相关的头示例。 [F05]

绿色与红色头显示不同连线模式，原文说行为 seems related to structure。

核心关注

结论边界：论文在所测翻译和解析设置中证明了一个强而可并行的注意力架构。它没有消除长序列的二次成本，没有用重复种子给出不确定性区间，也没有用定性图证明普遍可解释性。

论证主线原文线索

能否以纯注意力替代循环/卷积序列转导?

Transformer 采用注意力、前馈层、残差归一化和位置编码组成编码器-解码器。

纯注意力架构在所测试任务上实现了强质量与并行性的组合，但收益不是脱离规模、数据、解码和训练协议的单一机制效果。

证据来源与页面锚点

正文中的图表、公式和引文都保留了返回源材料的线索；需要逐项核实时可打开独立的审计视图。

当前稿件引用了 0 条主张、0 组图表和 0 张数据表。

页面锚点：[p.1](#)

[查看逐项来源与核验记录](#)